

MONA DRP

v3 Veri Modeli

Ölçeklenebilirlik Değerlendirmesi

Toplantı Notlarıyla Revize Edilmiş Sürüm

Haziran 2026 | Ağustos 2026 Deadline | 15 Tablo | 200M Aday/Gün Hedefi

1. Değerlendirme Kapsamı

Bu belge, Mona DRP v3 veri modelinin büyük hacimli kullanım altında nasıl davranacağını değerlendirmek için hazırlanmıştır. Revizyon, ER diyagramı ve tablo yapısı üzerinden yapılan ölçek analizi ile toplantı konuşmalarında çıkan mimari yönlendirmeleri birleştirir.

Kapsam notu: Bu belge mevcut 15 tabloluk MVP veri modelini hemen değiştirme önerisi değildir. Amaç; MVP çalışırken korunması gereken sınırları, yüksek ölçekte problem çıkarabilecek noktaları ve Scale Epic Backlog maddelerini netleştirmektir. Öncelik çalışan uçtan uca MVP akışını çıkarmaktır.

Bu revizyonda özellikle fazla mühendislik sayılabilecek bazı maddeler kapsam dışına alınmıştır: ID tipi/UUID optimizasyonu, cold storage yaşam döngüsü, ayrı analitik özet tabloları ve candidate durum geçmişi. Bu maddeler toplantıdaki öncelik ile doğrudan örtüşmediği için final belgeye alınmamıştır.

2. Genel Değerlendirme

v3 veri modeli iş mantığı açısından temiz bir yapıya sahiptir. Candidate tespitinden crawler sonucuna, page feature çıkarımından risk skoruna, human review'dan evidence dosyalarına kadar her adım ayrı sorumlulukla modellenmiştir. Bu ayrım MVP için anlaşılır, takip edilebilir ve genişletilebilir bir temel sağlar.

Büyük hacimde temel mesele tek bir tablonun büyümesi değildir. Bir aday sisteme girdiğinde ardından analiz, sinyal, skor, kural ve kanıt kayıtları oluşur. Bu nedenle asıl risk, candidates tablosundan başlayan fan-out etkisidir.

Kısa sonuç: v3 modeli MVP için uygundur; ancak 200M aday/gün hedefinde candidates, outbox_jobs, page_features, detection_signals, rule_results ve evidence_files en kritik büyüme noktalarıdır.

3. Hacim ve Büyüme Tahmini

Hedef senaryo: 100.000 korunan domain x 2.000 permütasyon = 200.000.000 aday/gün. Bu yalnızca candidates tablosuna gelebilecek giriş yüküdür. Pipeline devam ettikçe gerçek yazma hacmi bunun birkaç katına çıkabilir.

Tablo	Aday Başına Kayıt	200M Adayda Günlük Etki	Ölçek Riski
candidates	1	200M satır	Ana giriş ve status güncelleme baskısı
outbox_jobs	1-3	200M-600M job	Sürekli status güncellemesi
crawl_results	0-1	Erişilen aday sayısına bağlı	Fetch çıktısı ve redirect/metadata büyümesi
page_features	0-N	Tarama sayısına bağlı	dom_summary büyürse en kritik storage riski
candidate_asset_matches	1-4+	200M-800M+	Asset ve match_type sayısına göre çarpan etkisi
detection_signals	1-6	200M-1.2B	Sinyal sayısına göre hızlı büyüme
risk_scores	0-1	Analiz edilene bağlı	LLM summary boyutu kontrol edilmeli
rule_results	1-20+	1B-4B potansiyel	Tüm kurallar yazılırsa patlama riski
evidence_files	0-5	Kanıt politikasına bağlı	Dosya içeriği değil, sadece referans tutulmalı

10-15 TB/gün ve 300-450 TB/ay gibi büyüklükler kesin kapasite planı değildir; aday başına ortalama kayıt sayısı, JSONB boyutu ve dosya referansı varsayımlarıyla yapılan yaklaşık tahminlerdir. Bu tahminler tek bir klasik PostgreSQL kurulumunun sınırlarına yaklaşılabileceğini gösterir; partitioning, kuyruklama ve storage_ref tabanlı saklama kararlarının önceden düşünülmesi gerekir.

4. ER Diyagramında Merkezi Baskı Noktası

ER diyagramında operasyonel yük candidates tablosuyla başlar. entities, assets, asset_groups ve exclusions daha çok referans veri katmanıdır.

- candidates → crawl_results → page_features
- candidates → candidate_asset_matches
- candidates → detection_signals
- candidates → risk_scores → rule_results
- candidates → evidence_files
- candidates → reviews → cases

Bu yapı iş mantığı açısından doğrudur; fakat büyük hacimde her alt tablo candidate ile birlikte büyür. Bu nedenle candidate yönetimi, sadece veri üretimi değil, sistemin ölçek stratejisi açısından da ana karar noktasıdır.

5. Tablo Bazlı Kritik Değerlendirme

5.1 Referans Tablolar: entities, asset_groups, assets, exclusions

entities ve asset_groups hızlı büyümeyebilir; ölçek açısından düşük risklidir. assets tablosunda ana risk metadata alanıdır: referans logo yolu, favicon, homepage URL ve küçük DOM özeti tutulabilir; büyük

HTML, görsel binary veya uzun analiz çıktısı metadata içine konmamalıdır. exclusions ise sadece business allowlist değil, aynı zamanda erken filtreleme mekanizmasıdır. DNS/HTTP validation başlamadan önce exclusion kontrolü yapılırsa gereksiz validation ve crawl yükü azaltılır.

5.2 candidates — Ana Darboğaz

Tüm aday üretimi candidates etrafında şekillenir. Bu tablo hem çok fazla insert alır hem de discovered, validating, crawling, analyzed, scored, reviewed, closed gibi status geçişleriyle güncellenir. Bu yüzden büyüme riski sadece satır sayısı değil, sürekli güncelleme baskısıdır. metadata yalnızca küçük provenance bilgileri için kullanılmalı; ham tarama çıktısı veya büyük response verisi buraya konmamalıdır.

5.3 Candidate’a Ne Zaman Yazılmalı?

Toplantıda tartışılan ana karar şudur: Tüm permütasyonlar önce candidates tablosuna mı yazılacak, yoksa DNS/HTTP kontrolünden geçen aktif adaylar mı candidates’a alınacak? İlk yol takip kolaylığı sağlar ama tabloyu çok hızlı şişirir. İkinci yol tabloyu küçük tutar ama bugün inactive olan domainin daha sonra aktifleşmesini yakalamak için periyodik tekrar kontrol gerektirir. MVP’de mevcut candidate akışı korunabilir; ancak “Candidate Management / Candidate Ingestion Strategy” Scale Epic P1 olarak izlenmelidir. Bu ön filtreleme yeni kalıcı tablo anlamına gelmemeli; geçici bellek, job payload’ı, dış akış veya queue seviyesinde ele alınmalıdır.

5.4 crawl_results ve page_features

crawl_results site açılmadan üretilmeyen fetch çıktısını, page_features ise sayfa içeriğinden çıkarılan business feature’ları tutar. Bu ayırım v3’ün güçlü tarafıdır. Ancak redirect_chain ve dom_summary için sınır konmalıdır. Büyük HTML/DOM veya uzun redirect zinciri metadata, redirect_chain veya dom_summary gibi JSONB alanlarına gömülmemelidir. MVP’de PostgreSQL tabanlı bir storage yaklaşımı kullanılabilir; ancak bu içerikler storage_ref ile ayrı saklama katmanı üzerinden referanslanmalıdır. İleri fazda aynı yapı MinIO/S3 compatible storage’a taşınabilecek şekilde tasarlanmalıdır.

5.5 candidate_asset_matches — Paralel Benzerlik Analizi

Domain similarity, logo similarity, favicon similarity ve DOM similarity birbirinin alternatifi değildir; aynı aday için birden fazla match_type kaydı üretir. Bu analizlerin sırayla çalışması ileride darboğaz yaratır. MVP’de tek tablo yapısı korunabilir; fakat domain/logo/favicon/DOM hesaplamalarının aktörler halinde paralel çalışması ve sonuçlarını bağımsız satırlar olarak yazması Scale Epic altında ele alınmalıdır. İleri fazda asset ve match_type bazlı erişim/yazma paterni ile partitioning ihtiyacı ayrıca değerlendirilmelidir.

match_type değerleri genişlemeyi engellemeyecek şekilde açık isimlendirilmelidir. Örneğin yalnızca similarity gibi genel bir değer yerine domain_similarity, logo_similarity, favicon_similarity ve dom_similarity gibi ayrımlar kullanılmalıdır.

5.6 detection_signals

Form, password input, OCR brand match, suspicious text gibi sinyaller bu tabloda tutulur. Toplantı notlarına göre ödeme/checkout davranışı da önemli phishing sinyalidir. Bu nedenle payment_page_detected, checkout_redirect_detected veya card_input_detected gibi signal_type

değerleri ileride eklenebilir. String/open-enum yaklaşımı bu genişlemeyi şema değişikliği olmadan destekler.

5.7 risk_scores ve rule_results

risk_scores aday başına genellikle tek karar satırı üretir; llm_summary boyutu sınırlandırılmalıdır. rule_results açıklanabilirlik için değerlidir ancak tüm kurallar her aday için yazılırsa tablo çok hızlı büyür. Bu nedenle yalnızca tetiklenen, skora katkı veren veya human review için açıklama değeri taşıyan kural sonuçları yazılmalıdır.

5.8 reviews, cases ve evidence_files

reviews ve cases candidate sayısıyla birebir büyümemelidir; sadece riskli veya doğrulanmış adaylar bu katmana taşınmalıdır. evidence_files doğru şekilde referans tablosu olarak kalmalıdır. Screenshot, HTML archive, DOM snapshot ve OCR çıktısı ana operasyonel tablolardaki JSONB alanlarına gömülmemelidir. MVP’de bu dosyalar PostgreSQL tabanlı ayrı bir storage yapısında tutulabilir; evidence_files.storage_ref ise bu içeriğin referansını taşımalıdır. İleri fazda aynı storage_ref yaklaşımı MinIO/S3 tarafına taşınabilir.

5.9 outbox_jobs

outbox_jobs MVP için basit iş kuyruğu olarak uygundur; fakat 200M aday/gün seviyesinde en çok yazılan ve güncellenen tablolardan biri olur. Bu nedenle kod doğrudan tabloya bağımlı olmamalı; JobQueue arayüzü üzerinden yazmalı. İleri fazda aynı akış Producer-Consumer yapısına ve Kafka benzeri bir kuyruk modeline taşınabilecek şekilde düşünülmelidir. Tamamlanan işler tabloda sonsuza kadar birikmemeli; cleanup politikası MVP sonrasında ele alınmalıdır.

6. JSONB ve Büyük Veri Alanları

JSONB alanları MVP’de esneklik sağlar; ancak “ne gelirse buraya koyarım” alanı gibi kullanılmamalıdır. Her JSONB alanının küçük, tanımlı ve sınırlı bir amacı olmalıdır.

Alan	Risk	Net Kural
assets.metadata	Referans bilgiler büyüyebilir	Logo/favicon yolu ve URL ile sınırlı tut
candidates.metadata	Ham kaynak çıktısı taşınabilir	Sadece provenance/id bilgisi
crawl_results.redirect_chain	Uzun zincirler tabloyu şişirir	Maksimum hop sınırı; ham veri JSONB’ye gömülmez, gerekiyorsa storage_ref ile referanslanır
crawl_results.metadata	Telemetri kontrolden çıkabilir	SSL, header, fetch süresi gibi slim veri
page_features.dom_summary	En yüksek storage riski	Küçük özet; büyük DOM ana JSONB alanına gömülmez, storage_ref ile ayrı saklama katmanında tutulur
detection_signals.details	Ham OCR/metin/HTML dolabilir	Sinyal özeti ve skor; ham OCR/HTML/metin JSONB’ye gömülmez, gerekiyorsa storage_ref ile referanslanır
risk_scores.llm_summary	Uzun LLM çıktısı tabloyu ağırlaştırır	Karakter sınırı veya storage_ref

outbox_jobs.payload	Büyük payload queue tablosunu ağırlaştırır	Sadece id, job type ve küçük parametreler; HTML/DOM/OCR/screenshot gibi büyük veri payload içine konmaz
---------------------	--	--

7. İlişkiler, İndeks ve Partitioning Değerlendirmesi

Foreign key ilişkileri iş mantığı açısından doğrudur; candidate'dan evidence/case katmanına kadar izlenebilirlik sağlar. Büyük hacimde bu ilişkiler her yazma işlemine ek kontrol maliyeti getirir. Bu nedenle toplu yazma (batch insert), doğru indeksleme ve büyük tablolarda partitioning hazırlığı önemlidir.

Konu	Risk	Öneri
candidates(entity_id, status)	status sürekli değiştiği için indeks şişebilir	Aktif status'lar için daraltılmış indeks düşünülmeli
outbox_jobs(status, created_at)	pending/processing/done geçişleri hot spot yaratır	Sadece bekleyen/işlenen işler için daraltılmış indeks
rule_results(rule_code)	Milyarlarca satırda indeks ağırlaşır	Sadece fired=true veya skora katkı verenler için indeks
evidence_files(content_hash)	Boş değerler indeksi şişirir	content_hash IS NOT NULL için daraltılmış indeks
candidate_asset_matches	Paralel aktörler aynı tabloya yoğun yazar	asset_id, match_type ve zaman ekseninde partitioning değerlendirilir
Büyük append-only tablolar	Tek parça tablo yönetimi zorlaşır	candidates, crawl_results, detection_signals, rule_results için zaman bazlı partitioning planlanır

Partitioning bu aşamada hemen tablo sayısını artırmak veya MVP şemasını değiştirmek anlamına gelmez. Scale Epic altında izlenecek, veri büyümesi başladığında devreye alınacak bir hazırlık başlığıdır.

8. Modüler Monolit ve Proje Yapısı Ölçeklenebilirliği

Toplantı notlarına göre ölçek konusu sadece veritabanı tablosu sayısı değildir; uygulamanın yazma ve işleme biçimi veri modelini doğrudan etkiler. Bu nedenle MVP tek parça çalışan bir Scala Play uygulaması olabilir; ancak içeride modüler monolit olarak ayrışmalıdır. Amaç mikroservisleri hemen kurmak değil, ileride ayrılacak sınırları şimdiden temiz tutmaktır.

Modül	Sorumluluk	İleri Fazda Ayrılma Nedeni
common	Domain objeleri, ortak tipler, enum codec yaklaşımı	candidate/crawler/action modülleri aynı dili konuşur
candidate	Manual input, permutation, source/status yönetimi, exclusion kontrolü	Input kaynakları arttıkça ayrı ölçeklenebilir
crawler	DNS/HTTP validation, fetch, crawl_results üretimi	Crawler yoğun iş yükü bağımsız worker/servis olabilir

analysis	page_features, candidate_asset_matches, detection_signals, risk_scores	Benzerlik ve sinyal aktörleri paralel çalışabilir
action/takedown	reviews, cases, evidence package ve takedown mock/log	Aksiyon ve enforcement ileride ayrı servisleşebilir
storage/queue adapter	StorageService ve JobQueue arayüzleri	storage_ref/S3-MinIO ve Kafka geçişi izole edilir

Bu yapı MVP’yi gereksiz mikroservis karmaşıklığına sokmaz; fakat ileride Producer-Consumer yapısına, Kafka kuyruklarına, ayrı crawler worker’larına ve storage_ref tabanlı saklama katmanına geçişi kolaylaştırır. Bu saklama katmanı ileri fazda S3/MinIO compatible yapıya taşınabilir.

9. MVP Guardrail’leri

Aşağıdaki maddeler “hemen production-scale sistem kurmak” anlamına gelmez. MVP yazılırken yanlış alışkanlık oluşmasını engelleyen sınırlar olarak uygulanmalıdır.

1. Evidence dosyaları ana operasyonel tablolara binary veya büyük JSONB olarak gömülmemeli. MVP’de PostgreSQL tabanlı ayrı storage yaklaşımı kullanılabilir; ancak erişim storage_ref üzerinden yapılmalı ve yapı ileride MinIO/S3’e taşınabilecek şekilde tasarlanmalıdır.
2. dom_summary, redirect_chain, llm_summary ve outbox payload için boyut sınırı konmalı.
3. JobQueue arayüzü kullanılmalı; kod doğrudan outbox_jobs tablosuna gömülmemeli.
4. Similarity hesaplamaları ileride paralel aktörlere ayrılacak şekilde bağımsız tasarlanmalı.
5. rule_results yalnızca tetiklenen veya skora katkı veren kural sonuçlarını yazmalı.
6. Exclusion kontrolü DNS/HTTP validation’dan önce yapılmalı.
7. PostgreSQL migration’a geçmeden önce veri tipleri, nullable alanlar, foreign key ilişkileri, index ihtiyaçları ve status/type/signal_type/match_type gibi string/open-enum alanların değerleri kontrol edilmelidir.

10. Tablo Bazlı Risk Özeti

Tablo	Büyüme	Güncelleme	Ana Risk	Genel Risk
entities / asset_groups	Düşük	Düşük	Referans veri	Düşük
assets	Düşük-Orta	Düşük	metadata büyümesi	Düşük-Orta
exclusions	Orta	Orta	Geç uygulanırsa yük azaltamaz	Düşük-Orta
candidates	Çok yüksek	Çok yüksek	Ana fan-out ve status güncellemesi	Çok yüksek
crawl_results	Yüksek	Düşük	redirect/metadata büyümesi	Yüksek
page_features	Yüksek	Düşük	dom_summary şişmesi	Yüksek
candidate_asset_matches	Yüksek	Düşük	match_type ve asset çarpanı	Orta-Yüksek
detection_signals	Çok yüksek	Düşük	çoklu sinyal ve details büyümesi	Yüksek
risk_scores	Orta-Yüksek	Düşük	LLM summary boyutu	Orta
rule_results	Çok yüksek	Düşük	tüm kurallar yazılırsa patlar	Çok yüksek
reviews / cases	Düşük-Orta	Orta	yanlış filtreleme	Düşük-Orta
evidence_files	Yüksek	Düşük	dosya içeriği DB’ye girerse	Yüksek
outbox_jobs	Çok yüksek	Çok yüksek	job status güncellemesi	Çok yüksek

11. Scale Epic Backlog

Aşağıdaki maddeler mevcut 15 tabloluk MVP modelini hemen değiştirme önerisi değildir. Toplantıda çıkan risklerin backlog'a alınmış hâlidir.

Öncelik	İş Kalemi	Problem	Beklenen Fayda
P1	Candidate ingestion strategy	Tüm permütasyonlar mı yazılacak, yoksa DNS/HTTP sonrası aktif olanlar mı?	candidates tablosunun büyüme hızı kontrol edilir
P1	Evidence storage strategy	HTML/DOM/screenshot ana JSONB alanlarını şişirebilir	Binary/büyük içerik ana JSONB alanlarına gömülmez; storage_ref standardı kurulum ve ileri fazda MinIO/S3'e taşınabilir
P1	Exclusion-before-validation	Exclusion geç uygulanırsa gereksiz DNS/HTTP yükü oluşur	Validation ve crawl yükü azalır
P1	JobQueue + Producer-Consumer hazırlığı	Kod doğrudan outbox tablosuna bağımlı kalabilir	Kafka/queue geçişi daha az refactor ister
P2	Similarity analysis parallelization	Domain/logo/favicon/DOM similarity sequential çalışırsa darboğaz olur	Aktör bazlı paralel işleme hazırlanır
P2	Payment/checkout signal expansion	Ödeme yönlendirmesi önemli phishing sinyali	Risk tespiti güçlenir
P2	1.000-2.000 permutation smoke test	Tek domain için üretilen yüksek sayıda permutation'ın DB ve job akışına etkisi bilinmiyor	Candidate ingestion kararının gerçek MVP verisiyle test edilmesi sağlanır
P2	rule_results yazma politikası	Tüm kural sonuçları yazılırsa tablo patlar	Sadece tetiklenen/skora katkı veren kurallar tutulur
P2	JSONB size guardrails	dom_summary, redirect_chain, payload sınırsız büyüyebilir	Tablo şişmesi engellenir
P3	Table partitioning plan	Büyük tablolar tek parça kalırsa yazma/sorgu maliyeti artar	candidates, outbox_jobs, matches ve signals daha yönetilebilir olur
P3	Inactive permutation revalidation	Bugün inactive olan domain yarın aktif olabilir	Periyodik yeniden kontrol stratejisi belirlenir
P3	outbox_jobs cleanup	Tamamlanan işler tabloda birikir	Kuyruk tablosu küçük ve hızlı kalır

P1: MVP bitmeden karar/veri akışı sınırı netleşmeli. P2: MVP biter bitmez ele alınmalı. P3: Scale hazırlığı olarak planlanmalı.

12. Ana Bulgular

1. Model MVP için doğru; büyük ölçek için ek kararlar gerekiyor. Sorun mevcut 15 tablo değil, bu tabloların 200M aday/gün hacminde nasıl besleneceğidir.
2. Asıl risk tek tablo büyümesi değil, candidate etrafındaki veri çoğalmasındır. Her aday crawl, feature, signal, score, rule ve evidence kayıtları üretir.
3. Exclusions erken çalışırsa sistem yükünü azaltır. DNS/HTTP validation'dan önce exclusion kontrolü yapılmalıdır.
4. Benzerlik analizinin paralel aktör yapısı veri modelinin yazma şeklini etkiler. Sequential çalışma yüksek hacimde darboğazdır.
5. JSONB ve evidence dosyaları disiplinle yönetilmelidir. Büyük HTML/DOM/screenshot verisi ana analiz tablolarındaki JSONB alanlarına gömülmemelidir. MVP'de PostgreSQL tabanlı storage kullanılabilir; ancak bu içerikler storage_ref mantığıyla ayrı referanslanmalıdır.
6. outbox_jobs MVP için uygundur; ancak ileride Producer-Consumer ve Kafka benzeri kuyruk yapısına evrilebilecek şekilde arayüz arkasına alınmalıdır.
7. Modüler monolit yaklaşımı MVP sadeliğini korur, ileride candidate/crawler/analysis/action modüllerinin ayrılmasını kolaylaştırır.

13. Sonuç

Mona DRP v3 veri modeli MVP için güçlü bir başlangıç noktasıdır. İş mantığı temiz ayrılmış, temel pipeline anlaşılır biçimde kurulmuştur. Ancak 200M aday/gün hedefinde ölçek problemi sadece veritabanı tablosu büyümesi değil; candidate ingestion, queue/producer-consumer akışı, paralel analiz aktörleri, JSONB sınırları ve evidence dosyalarının storage_ref tabanlı saklama mantığıyla yönetilmesiyle birlikte düşünülmelidir. Bu yapı ileri fazda dış depolamaya taşınabilecek şekilde tasarlanmalıdır.

Bu nedenle final öneri: MVP şeması bu aşamada büyütülmemeli; çalışan uçtan uca akış çıkarılmalı. Fakat candidate yönetimi, evidence storage, JobQueue/Producer-Consumer hazırlığı, similarity parallelization, payment signal genişlemesi ve partitioning planı Scale Epic Backlog'da net şekilde takip edilmelidir.