

MONA DRP

MVP Core Veri Modeli

Güncel Şema, İlişkiler ve İndeksler — v5

Haziran 2026 | Ağustos 2026 Deadline

Bu belge ne içerir?

Mona DRP MVP Core veri modelinin güncellenmiş ölçeklenebilirlik uyumlu hâli: 16 tablo, alanları, aralarındaki foreign key ilişkileri ve önerilen index'ler. v2'ye göre alınan şema kararları (crawl_results bölünmesi, evidence_files immutability, rule_results ve exclusions tabloları, uniform created_at) bu belgeye işlenmiştir. Anlam ve şema yapısı v5 scalability revizyonunu kapsar: candidate_discoveries ve blob_storage eklendi, outbox_jobs PGMQ'ye taşındı, JSONB/TEXT guardrail'leri ve partial index'ler eklendi.

İçindekiler

1. v2'ye Göre Değişenler	3
2. Audit Konvansiyonu (şemaya yansıyan kural)	3
3. Tablo Tablo Şema	3
3.1 Varlık ve Asset Katmanı	4
3.2 Aday ve Tespit Katmanı	5
3.3 Karar ve Aksiyon Katmanı	8
3.4 Altyapı	10
4. Foreign Key İlişkileri — Tam Liste	10
5. Önerilen Index'ler	11
6. Bilinçli Olarak Ertelenenler	13

1. v2'ye Göre Değişenler

- **crawl_results bölündü** → crawl_results (fetch) + page_features (extraction). Hosting alanları (resolved_ip, asn, asn_org, hosting_provider, ip_country) JSONB'den kolona terfi etti; geri kalan telemetri slim metadata'da kaldı; created_at eklendi.
- **evidence_files** artık gerçekten immutable: case_id kaldırıldı (case bağlantısı candidate_id üzerinden türetilir); updated_at yok.
- **risk_scores**: IIm_summary TEXT kolonu eklendi; reasons slimplendi (rules dizisi rule_results'a taşındı).
- **rule_results**: yeni tablo (ateşleyen kurallar satır bazında).
- **exclusions**: yeni tablo (allowlist / kontrol edilmeyecek varlıklar).
- **reviews**: uniform created_at eklendi (reviewed_at domain alanı olarak kaldı).

v3 → v5 Scalability Revizyonu

- **candidate_discoveries eklendi**: Tüm permütasyonlar artık doğrudan candidates tablosuna yazılmaz. candidate_discoveries staging tablosunda exclusion ve DNS/HTTP kontrolünden geçer; sadece aktif adaylar candidates'a terfi eder.
- **outbox_jobs kaldırıldı**: Custom queue tablosu yerine PostgreSQL üzerinde PGMQ tabanlı JobQueue kullanılır. Uygulama kodu JobQueue interface'ine bağlıdır.
- **blob_storage eklendi**: HTML, DOM, screenshot, OCR, favicon/logo gibi büyük içerikler ana JSONB alanlarına gömülmez; blob_storage tablosunda bytea olarak tutulur.
- storage_ref standardı netleştirildi: crawl_results.storage_ref crawl_bundle/manifest referansı, evidence_files.storage_ref tekil kanıt dosyası referansıdır. Standart format: pg://evidence/{candidate_id}/{crawl_run_id}/{file_type}.{ext}
- **candidates.status listesine 'error' eklendi**: Pipeline adımı başarısız olduğunda stuck kalmayı önler.
- Partial index'ler uygulandı: candidates ve evidence_files index'leri daraltıldı; rule_results için risk_score_id index'leri ayrıştırıldı.

2. Audit Konvansiyonu (şemaya yansıyan kural)

Mutable tablolar → created_at + updated_at: entities, asset_groups, assets, candidates, candidate_discoveries, cases, exclusions.

Immutable tablolar → tek tip created_at; crawled_at / reviewed_at / timestamp gibi domain damgaları onun yanında: crawl_results, page_features, candidate_asset_matches, detection_signals, risk_scores, rule_results, reviews, evidence_files, blob_storage.

Kod temsili notu: type, asset_type, source, status, signal_type, match_type, verdict, rule_code, reason gibi alanlar DB'de string'dir; kodda sealed/open enum + tek codec ile temsil edilir (literal kullanılmaz). Büyüyen kümelerde Unknown(raw) fallback'li open-enum.

3. Tablo Tablo Şema

3.1 Varlık ve Asset Katmanı

entities (mutable)

Korunan marka, kurum veya kişi. Her şey buradan başlar.

id

PK — birincil anahtar.

name	Örn. "Akbank", "A101".
type	string (brand person institution ...). Enum değil; kodda enum+codec.
created_at, updated_at	Oluşturulma / son güncelleme (history değil, tek alanlık takip).

asset_groups (mutable)*Entity altında opsiyonel alt gruplama. MVP'de boş kalabilir.*

id	PK.
entity_id	FK → entities.id. Zorunlu.
name	Örn. "Akbank Direkt", "Axess".
created_at, updated_at	Oluşturulma / son güncelleme.

assets (mutable)*Entity'e ait korunan ana dijital varlık (domain/subdomain).*

id	PK.
entity_id	FK → entities.id. Zorunlu.
asset_group_id	FK → asset_groups.id. NULLABLE.
asset_type	string (domain subdomain). Logo/favicon ayrı tip değil; metadata'da.
value	Asset'in kendisi, örn. "akbank.com".
metadata	JSONB. Sadece küçük referans bilgileri tutulur: homepage_url, login_page_url, logo_ref, favicon_ref ve reference_dom_summary gibi özet/ref alanları. Logo, favicon, full reference DOM veya binary/base64 içerik metadata içine gömülmez; gerekiyorsa blob_storage üzerinden storage_ref ile tutulur.
is_active	bool (default true). Silme yerine pasifleştirme.
created_at, updated_at	Oluşturulma / son güncelleme.

exclusions (mutable) — YENİ*Allowlist / kontrol edilmeyecek varlıklar (sahip-ama-korunmayan, üçüncü-taraf meşru, manuel).*

id	PK.
entity_id	FK → entities.id. NULLABLE (ileride global dışlama için).
value	Dışlanacak domain/URL.
match_type	string (exact registrable_domain subdomain_of pattern).
reason	string (manual owned_unmonitored third_party_legit ...).
is_active	bool.
created_at, updated_at, created_by	mutable; created_by current-user seam'ine bağlı.

Not: Exclusion kontrolü `candidate_discoveries` aşamasında uygulanır. Eğer üretilen domain/URL aktif exclusion ile eşleşirse `candidates` tablosuna promote edilmez; `candidate_discoveries.skip_reason = 'whitelisted'` olarak kalır.

3.2 Aday ve Tespit Katmanı

candidate_discoveries (mutable) <i>Ham permütasyon ve dış kaynaklardan gelen keşifleri tutan ön eleme staging tablosu. Analiz tablosu değildir.</i>	
id	PK — BIGSERIAL.
entity_id	FK → entities.id. Zorunlu.
asset_id	FK → assets.id. NULLABLE. Permütasyon kaynağı asset. ct_log/complaint gibi dış kaynaklarda NULL olabilir.
value	Ham domain/URL değeri.
normalized_value	Normalize edilmiş değer (lowercase, scheme çıkarılmış). Duplicate guard bu üzerinden çalışır.
source	string (permutation ct_log whois_feed manual_bulk complaint).
dns_status	string (pending active inactive error). DNS/HTTP kontrol sonucu.
http_status_code	INT. NULLABLE. HTTP yanıt kodu.
skip_reason	string (whitelisted duplicate invalid_format). NULLABLE. Neden atlandı.
failed_check_count	INT. Kaç kez BAŞARISIZ (inactive/error) kontrol edildiği. Yalnızca başarısız denemelerde artar; aktif aday terfi edip recheck döngüsünden çıkınca okunmaz. Exponential backoff için.
last_checked_at	TIMESTAMPTZ. Son kontrol zamanı.
next_check_at	TIMESTAMPTZ. Bir sonraki kontrol zamanı. failed_check_count arttıkça süre uzar. next_check_at = now() + f(failed_check_count)
created_at	TIMESTAMPTZ DEFAULT now().
updated_at	TIMESTAMPTZ DEFAULT now().

Not: DNS/HTTP'den geçen aktif adaylar `candidates`'a terfi eder. İnaktif olanlar `next_check_at` ile periyodik recheck'e alınır (exponential backoff). Duplicate guard `candidate_discoveries(entity_id, normalized_value)` üzerinden sağlanır; `candidates` tablosu ham lookup/duplicate kontrol tablosu değildir. Bu tablo hafif tutulur: JSONB alan, HTML/DOM/screenshot içerik ve ağır cascade yoktur.

candidates (mutable) <i>candidate_discoveries aşamasında exclusion ve DNS/HTTP kontrolünden geçerek analiz pipeline'ına alınmaya değer bulunan gerçek adaylar. Ham permütasyon havuzu değildir.</i>	
id	PK.
entity_id	FK → entities.id. Zorunlu.
discovery_id	FK → candidate_discoveries.id. NULLABLE — terfi eden adayda dolu; manuel/dış kaynak adayları staging'e uğramadan girebildiği için zorunlu değil.
source	string (manual permutation ct_log whois_feed sikayetvar ...).
value	Tam URL/FQDN (registrable domain değil; örn. akbank.com.guvenli-giris.xyz).

status	string (validated → crawled → analyzed → scored → reviewed → closed eliminated error). Not: whitelisted, candidates aşamasına gelmiş bir adayın istisnai manuel kapatması için terminal status olarak kullanılabilir. Normal dışlama akışı candidate_discoveries.skip_reason üzerinden yürür.
metadata	JSONB. Sadece küçük provenance bilgileri: complaint_id, ct_cert_id, üretildiği orijinal domain. Ham DNS/HTTP response veya büyük payload girilmez.
discovered_at	İlk keşif zamanı.
created_at, updated_at	Kayıt / son güncelleme.

crawl_results (immutable)*FETCH — site tekrar açılmadan üretilmeyen gözlemlenen veri. Fetch başına 1.*

id	PK.
candidate_id	FK → candidates.id. Zorunlu.
http_status	HTTP yanıt kodu.
redirect_chain	Yönlendirme zinciri.
final_url	Son URL.
resolved_ip	metadata'dan KOLONA terfi (threat-graph query-kritik).
asn	kolon.
asn_org	kolon.
hosting_provider	kolon.
ip_country	kolon.
storage_ref	Crawl sırasında üretilen büyük içeriklere ait bundle/manifest referansıdır. Bu ref, blob_storage içinde file_type = 'crawl_bundle' olan JSON manifest kaydına işaret eder. Manifest içinde html_ref, dom_ref ve screenshot_ref gibi tekil storage_ref değerleri bulunur. Standart format: pg://evidence/{candidate_id}/{crawl_run_id}/{file_type}.{ext}.
metadata	JSONB slim/telemetry: ssl_info, server_header, content_type, fetch_duration_ms, blocked_by_bot_protection, crawl_user_agent. Full HTML veya raw response girmez.
crawled_at	Crawl zamanı (domain damgası).
created_at	Uniform oluşturma damgası.

page_features (immutable) — YENİ*EXTRACTION — storage'dan re-derive edilebilir, versiyonlu. Crawl başına extractor_version bazında 1 satır.*

id	PK.
crawl_result_id	FK → crawl_results.id. Zorunlu.

title	Sayfa başlığı.
has_form	Sayfada form var mı.
has_password_input	Şifre alanı var mı.
brand_name_found	Sayfa metninde marka adı geçiyor mu (ham boolean).
dom_summary	JSONB. Yapısal özet: form_count, input_count, password_input_count, button_count, external_script_count gibi küçük sayısal özetler. Full DOM buraya gelmez; tam DOM crawl_results.storage_ref üzerinden blob_storage'da.
extractor_version	Hangi extraction mantığının ürettiği.
created_at	Oluşturma.

Not: Crawl başına extractor_version bazında tek satır yazılır. Aynı crawl_result_id ve extractor_version için unique index kullanılır; bu extraction job'larının idempotent çalışmasını sağlar. Extraction mantığı değişirse aynı crawl_result_id/storage_ref üzerinden yeni extractor_version'lı satır yazılır — re-fetch/mutation yok.

candidate_asset_matches *(immutable)*

Adayın resmi asset'e ne kadar benzediği — skorlar.

id	PK.
candidate_id	FK → candidates.id. Zorunlu.
asset_id	FK → assets.id. Zorunlu.
crawl_result_id	FK → crawl_results.id. NULLABLE.
similarity_score	0–1 benzerlik skoru.
match_type	string (domain_similarity logo_similarity favicon_similarity reference_dom_similarity).
details	JSONB. Skorun nasıl hesaplandığını anlatan küçük teknik özet. Logo binary, favicon binary, screenshot veya full DOM buraya gelmez; büyük içerikler blob_storage/evidence_files üzerinden saklanır.
created_at	Kayıt zamanı.

Not: DOM-tabanlı match (reference_dom_similarity), dom_summary'yi page_features'tan crawl_result_id üzerinden okur. Provenance gerekirse ileride page_features_id eklenir.

detection_signals *(immutable)*

Sayfanın İÇİNDEN çıkan, asset'e referans vermeyen sinyaller.

id	PK.
candidate_id	FK → candidates.id. Zorunlu.
crawl_result_id	FK → crawl_results.id. NULLABLE.
signal_type	string (form_detected password_input_detected ocr_brand_match brand_keyword_found suspicious_login_text html_fingerprint).
score	Sinyalin gücü/skoru.

details	JSONB. Sinyalin özeti: matched_brand, confidence, matched_text_snippet, field/source bilgisi. Ham OCR çıktısı, full HTML veya uzun text dump girmez → evidence_files.storage_ref.
metadata	JSONB. Küçük teknik metadata. Full HTML, raw OCR, screenshot, binary/base64 veya uzun text dump içermez.
created_at	Kayıt zamanı.

3.3 Karar ve Aksiyon Katmanı

risk_scores (immutable)

Toplanan sinyallerden üretilen nihai, açıklanabilir karar.

id	PK.
candidate_id	FK → candidates.id. Zorunlu.
crawl_result_id	FK → crawl_results.id. NULLABLE.
total_score	Ağırlıklandırılmış toplam skor.
verdict	string (clean suspicious malicious).
confidence	NULLABLE. Human-review önceliklendirme.
reasons	JSONB slim. Kısa karar gerekçeleri ve küçük bağlam bilgisi. Full rule dump, uzun LLM response veya ham sinyal çıktısı içermez.
llm_summary	TEXT. Özet karar açıklaması. Full LLM response veya reasoning log girmez. CHECK: 5000 karakter.
rule_set_version	Hangi kural setiyle üretildiği.
created_at	Kayıt zamanı.

rule_results (immutable) — YENİ

id	PK.
risk_score_id	FK → risk_scores.id. Zorunlu.
rule_code	string. Kural kodu.
weight	numeric. Katkı ağırlığı.
detail	JSONB. NULLABLE. Kuralın küçük açıklama detayı. Full HTML, OCR, screenshot veya uzun sinyal çıktısı içermez.
created_at	Kayıt zamanı.

reviews (immutable / append-only)

İnsan inceleme kararı. En son satır en güncel kabul edilir.

id	PK.
-----------	-----

candidate_id	FK → candidates.id. Zorunlu.
risk_score_id	FK → risk_scores.id. NULLABLE.
reviewer	Kararı veren analist.
decision	string (confirmed false_positive needs_more_info).
notes	Analist notu.
reviewed_at	İnceleme zamanı (domain damgası).
created_at	YENİ — uniform oluşturma damgası.

cases (mutable)*Onaylanmış tehdit için açılan vaka/aksiyon kaydı.*

id	PK.
candidate_id	FK → candidates.id. Zorunlu.
review_id	FK → reviews.id. NULLABLE.
status	string (open takedown_requested closed false_positive).
priority	NULLABLE (low/medium/high). Aksiyon önceliği.
takedown_sent_at	Takedown talebinin (mock/log) gönderildiği zaman.
notes	Vaka notu.
created_at, updated_at	Oluşturulma / son güncelleme.

evidence_files (immutable)*Kanıt dosyalarının depolama referansları. Write-once.*

id	PK.
candidate_id	FK → candidates.id. Zorunlu.
crawl_result_id	FK → crawl_results.id. NULLABLE.
file_type	string (screenshot html_archive dom_snapshot ocr_output favicon logo).
storage_ref	Tekil kanıt dosyası referansı. blob_storage.storage_ref formatına uyar. Dosyanın gerçek içeriği evidence_files'ta değil blob_storage.data'da tutulur.
content_hash	NULLABLE. Dosya parmak izi. blob_storage.content_hash ile aynı değer. Recurrence detection ve dedup için kullanılır.
timestamp	Dosyanın üretildiği an (domain damgası).
created_at	Kayıt zamanı.

Not: case_id YOK. "Bu case'in kanıtı" = case → candidate_id → evidence_files (ortak candidate_id). İleride curated/m:n için case_evidence join tablosu eklenir (kırıcı değil).

3.4 Altyapı

blob_storage (immutable / append-only)

MVP'de S3/MinIO kullanılmadığı için büyük binary/text içerikleri PostgreSQL içinde tutan storage tablosu. Uygulama kodu StorageService interface üzerinden erişir.

id	PK — BIGSERIAL.
storage_ref	TEXT. UNIQUE. Erişim anahtarı. Standart format: pg://evidence/{candidate_id}/{crawl_run_id}/{file_type}.{ext}. İleride S3: s3://mona-drp/evidence/...
file_type	string (html_archive screenshot dom_snapshot ocr_output favicon logo crawl_bundle).
content_type	string (text/html image/png image/jpeg application/json text/plain).
data	BYTEA. STORAGE EXTERNAL. Gerçek binary içerik. Text dosyalar (HTML, DOM, OCR) uygulama tarafında gzip'lenerek yazılır. PNG/JPEG doğrudan saklanır.
size_bytes	BIGINT. Dosya boyutu.
content_hash	TEXT. NULLABLE. SHA-256. Recurrence detection ve dedup için. evidence_files.content_hash ile aynı değer.
compression	string (none gzip). HTML/DOM/OCR → gzip. PNG/JPEG → none.
created_at	TIMESTAMPTZ DEFAULT now().

PGMQ / JobQueue (outbox_jobs'un yerini aldı)

outbox_jobs tablosu veri modelinden çıkarılmıştır. İş kuyruğu sorumluluğu PostgreSQL içinde çalışan PGMQ'ye taşınmıştır. Uygulama kodu doğrudan PGMQ fonksiyonlarına değil, JobQueue interface'ine bağlıdır. Queue mesajları yalnızca target_type, target_id, job_type ve küçük parametreler taşır; HTML, DOM, OCR, screenshot gibi büyük içerikler payload'a girmez.

candidate_validation_queue → DNS/HTTP kontrolü

crawl_queue → crawler işleri

feature_extraction_queue → page feature çıkarımı

similarity_queue → domain/logo/favicon/DOM similarity analizi

risk_scoring_queue → risk skoru hesaplama

Not: Worker'lar idempotent çalışmalıdır. Aynı mesaj tekrar işlense bile aynı candidate iki kez promote edilmemelidir, aynı crawl_result veya page_features satırı duplicate oluşmamalıdır.

4. Foreign Key İlişkileri — Tam Liste

Alan	Referans	Durum
asset_groups.entity_id	→ entities.id	Zorunlu
assets.entity_id	→ entities.id	Zorunlu
assets.asset_group_id	→ asset_groups.id	Nullable
exclusions.entity_id	→ entities.id	Nullable
candidates.entity_id	→ entities.id	Zorunlu
crawl_results.candidate_id	→ candidates.id	Zorunlu
page_features.crawl_result_id	→ crawl_results.id	Zorunlu
candidate_asset_matches.candidate_id	→ candidates.id	Zorunlu
candidate_asset_matches.asset_id	→ assets.id	Zorunlu
candidate_asset_matches.crawl_result_id	→ crawl_results.id	Nullable

Alan	Referans	Durum
detection_signals.candidate_id	→ candidates.id	Zorunlu
detection_signals.crawl_result_id	→ crawl_results.id	Nullable
risk_scores.candidate_id	→ candidates.id	Zorunlu
risk_scores.crawl_result_id	→ crawl_results.id	Nullable
rule_results.risk_score_id	→ risk_scores.id	Zorunlu
reviews.candidate_id	→ candidates.id	Zorunlu
reviews.risk_score_id	→ risk_scores.id	Nullable
cases.candidate_id	→ candidates.id	Zorunlu
cases.review_id	→ reviews.id	Nullable
evidence_files.candidate_id	→ candidates.id	Zorunlu
evidence_files.crawl_result_id	→ crawl_results.id	Nullable
candidate_discoveries.entity_id	→ entities.id	Zorunlu
candidate_discoveries.asset_id	→ assets.id	Nullable
candidates.discovery_id	→ candidate_discoveries.id	Nullable

Not: blob_storage ilişkisi storage_ref string standardı üzerinden kurulur. İleride S3/MinIO geçişinde FK yerine StorageService interface kullanıldığı için fiziksel FK bilinçli olarak konmaz.

5. Önerilen Index'ler

- candidates(entity_id, created_at) WHERE status IN ('validated', 'crawled', 'analyzed', 'scored', 'reviewed') – partial (aktif adaylar)
- assets(entity_id, asset_type, value)
- exclusions(entity_id, is_active)
- crawl_results(candidate_id, crawled_at)
- page_features(crawl_result_id)
- candidate_asset_matches(candidate_id)
- detection_signals(candidate_id, signal_type)
- risk_scores(candidate_id, created_at)
- rule_results(risk_score_id)
- reviews(candidate_id)
- cases(candidate_id, status)
- evidence_files(candidate_id) – case→candidate üzerinden kanıt çekme
- evidence_files(content_hash) WHERE content_hash IS NOT NULL – partial (recurrence monitoring)

– candidate_discoveries –
candidate_discoveries(entity_id, normalized_value) – UNIQUE
candidate_discoveries(entity_id, created_at) WHERE dns_status = 'pending' AND skip_reason IS NULL
candidate_discoveries(next_check_at) WHERE dns_status = 'inactive' AND skip_reason IS NULL
candidate_discoveries(asset_id) WHERE asset_id IS NOT NULL

– candidates (ek) –
candidates(status, updated_at) WHERE status IN ('validated', 'crawled', 'analyzed', 'scored', 'reviewed')

– page_features –

```
page_features(crawl_result_id, extractor_version) - UNIQUE (idempotency)
- blob_storage -
blob_storage(content_hash) WHERE content_hash IS NOT NULL
blob_storage(created_at)
```

6. Bilinçli Olarak Ertelenenler

Aşağıdakiler şemayı kırmadan ileride eklenebilir:

- **audit_logs / case_events / candidate_status_history** — tam versioning/audit. İleri faz; mevcut şemayı bozmaz.
- **threat_links** — Threat Graph node-edge tablosu. Ham veri (resolved_ip/asn/hosting_provider artık kolon; fingerprint/favicon hash detection_signals & evidence_files'ta) hazır; yalnızca bağlantı tablosu eksik.
- **page_features_id downstream FK** — extraction-versiyon provenance gerektiğinde detection_signals / candidate_asset_matches / risk_scores / evidence_files'a eklenir.
- **case_evidence (join)** — curated/çoklu-case kanıt bağlama gerektiğinde.
- **rule_results üzerinden tam analitik** — tablo şimdi kuruldu; self-improving/rule-tuning sorguları devreye girince ek index/materialized view ile genişletilir.
- **created_by / updated_by / deletedBy** — current-user seam'i (auth/RBAC) geldiğinde.
- **S3/MinIO migration:** blob_storage MVP'de kullanılır. İleri fazda StorageService implementasyonu değiştirilerek S3/MinIO'ya geçilir. Veri modeli değişmez.
- **Kafka migration:** PGMQ MVP'de kullanılır. İleri fazda JobQueue interface'in Kafka implementasyonu yazılır. İş mantığı değişmez.
- **Retention/cleanup politikası:** candidate_discoveries ve blob_storage için yaşa ve risk seviyesine göre retention politikası. İleri faz.
- **Büyük tablo partitioning:** candidate_discoveries, candidates, crawl_results, detection_signals, rule_results, blob_storage için created_at bazlı partitioning. Scale Epic P3.